

Model Optimization Techniques

Baseline

採用前面所建構的 BasicCNN 模型，該架構包含三層卷積層 (Conv2d)、BatchNorm2d 以及兩層全連接層 (Linear)。在 CIFAR-10 資料集上對其進行了完整訓練，以作為後續優化技術的比較基準。

基準測試結果 (Float32 Baseline)：

```
=====
Performance Analysis: Float32 Baseline
=====
1. Parameters: 4.2934 M
2. Model Size: 17.18 MB
3. FLOPs:      0.014522 GFLOPs
4. Latency:    0.50 ms (avg over 100 runs)
5. Accuracy:   83.02%
=====
```

此 Float32 模型準確率表現優異，但其 17.18 MB 的大小對於 Edge Devices 仍有壓縮空間，將以此為基準進行 PTQ、Structured Pruning 與 Knowledge Distillation。

PTQ int8

應用了 Static Post-Training Quantization。使用 PyTorch 的 fbgemm 後端，先將模型中的 Conv2d + BatchNorm2d + ReLU 層進行模組 Fusion 以減少記憶體存取，接著透過驗證集資料進行 Calibration，最終將 FP32 權重轉換為 INT8 格式。量化後測試結果 (PTQ int8)：

```
=====
Performance Analysis: PTQ int8
=====
2. Model Size: 4.32 MB
3. FLOPs:      N/A (Quantized)
4. Latency:    0.55 ms (avg over 100 runs)
5. Accuracy:   83.00%
=====
```

量化技術取得了顯著的成效。模型大小從 17.18 MB 縮減至 4.32 MB，達成 4 倍壓縮率 (~75% 空間節省)。準確率僅微幅下降 0.02% (83.02% → 83.00%)，證明了 8-bit 的精度已足夠表示 CIFAR-10 的特徵分佈。

Structured Pruning

實作了 Layer-wise Structured Pruning。以 L1-norm 作為 Filter 的重要性評分標準，將每一層卷積層中 L1-norm 最低的 30% Filters 物理移除，並重新構建下一層的 Cascade dimensions 與全連接層維度。

剪枝與微調結果 (Pruned Model)：

```
Original Channels: 32 -> 64 -> 128
Pruned Channels  : 22 -> 45 -> 89
```

```
Fine-tuning pruned model for 5 epochs (lr=1e-4)...
Epoch [1/5] - Train Loss: 0.7133 - Val Acc: 78.52%
Epoch [2/5] - Train Loss: 0.5898 - Val Acc: 79.67%
Epoch [3/5] - Train Loss: 0.5587 - Val Acc: 80.26%
Epoch [4/5] - Train Loss: 0.5400 - Val Acc: 80.88%
Epoch [5/5] - Train Loss: 0.5266 - Val Acc: 80.81%
```

```
=====
Performance Analysis: Pruned Model
=====
1. Parameters: 2.9679 M
2. Model Size: 11.88 MB
3. FLOPs:      0.008118 GFLOPs
4. Latency:    0.54 ms (avg over 100 runs)
5. Accuracy:   80.81%
=====
```

結構化剪枝成功縮減了網路。FLOPs 從原本的 0.0145 G 降至 0.0081 G (運算負擔減少約 44%)，模型大小也降至 11.88 MB。雖然剪枝初期會破壞特徵圖導致失真，但僅經過 5 個 Epochs 的 Fine-tuning，準確率就順利恢復至 80.81%，去除冗餘 Filters 並不影響網路的核心學習能力。

Knowledge Distillation

為了突破學生模型 (BasicCNN) 的準確度上限，引入了官方的 ResNet-50 (IMAGENET1K_V2) 作為教師模型，並在訓練時將圖片放大至 224x224 讓教師模型提取特徵。結合了 KL Divergence (Soft loss) 與 Cross-Entropy (Hard loss) 進行 30 個 Epochs 的蒸餾訓練，設定

溫度參數 $T=4$ ，權重 $\alpha=0.9$ 。


知識蒸餾結果 (Distilled Student)：

```
=====
Performance Analysis: Distilled Student
=====
1. Parameters: 4.2934 M
2. Model Size: 17.18 MB
3. FLOPs:      0.014522 GFLOPs
4. Latency:    0.55 ms (avg over 100 runs)
5. Accuracy:   85.00%
=====
```

知識蒸餾展現了不增加運算成本卻提升效能的能力。學生模型的架構與大小 (17.18 MB) 完全沒有改變，但準確率卻從原本的 83.02% 升至 85.00%。學生模型成功透過 Soft labels 學習到了 ResNet-50 教師模型中的 Dark Knowledge，不同類別之間的相似性關聯。

Comparative Analysis

Optimization Summary		
Model Variant	Accuracy (%)	Model Size (MB)
1. Float32 Baseline	83.02	17.18
2. PTQ int8	83.00	4.32
3. Pruned Model	81.13	11.88
4. Distilled Student	85.00	17.18



長條圖 (綠色) 顯示 PTQ int8 在壓縮儲存空間上表現最佳

(17.18 MB→ 4.32 MB) 。

折線圖 (深藍色) 顯示 Knowledge Distillation 在提升模型準確率上達到最高點

(83.02%→85.00%) 。

Bonus Task

進一步將剪枝後的模型進行 PTQ 量化。結合兩種技術後，模型大小從 17.18 MB 縮小至僅 2.99 MB，且準確率仍能維持在 79.76%。


```
=====
Performance Analysis: Pruned + PTQ int8
=====
2. Model Size: 2.99 MB
3. FLOPs:      N/A (Quantized)
4. Latency:    1.15 ms (avg over 100 runs)
5. Accuracy:   79.76%
=====
```

針對 $T \in \{2, 4, 8\}$ 與 $\alpha \in \{0.7, 0.9\}$ 進行實驗。本專案中最佳的參數組合為 $T=4$, $\alpha=0.7$ ，該組合在短短 5 個 Epoch 的訓練中就達到了 76.97% 的準確率，說明適當

的溫度與軟標籤權重能有效幫助學生吸收知識。

[T=2		$\alpha=0.7$	]	-> Val Acc: 76.06%
[T=2		$\alpha=0.9$	]	-> Val Acc: 75.20%
[T=4		$\alpha=0.7$	]	-> Val Acc: 76.97%
[T=4		$\alpha=0.9$	]	-> Val Acc: 75.59%
[T=8		$\alpha=0.7$	]	-> Val Acc: 73.88%
[T=8		$\alpha=0.9$	]	-> Val Acc: 74.99%

Dark Knowledge：當 $T=1$ 時，教師模型的預測非常絕對；當溫度提升至 $T=4$ 時，分佈變得平滑，其餘錯誤類別的微小機率被明顯放大。



Code Appendix

<https://github.com/Wzx0110/Model-Optimization-Techniques.git>